

EthicBuild：基于价值手册与风险控制引擎的大模型辅助项目构建系统设计与实现

摘要

大语言模型正在被广泛用于项目构思、代码生成和系统设计。此类工具在提升开发效率的同时，也可能放大隐私侵犯、算法偏见、技术滥用、透明性不足和责任归属不清等伦理风险。本文设计并实现了 EthicBuild，一个面向大模型辅助项目构建场景的伦理护栏式系统。系统并不将伦理控制简化为提示词约束，而是将伦理价值编码为机器可读的价值手册，并通过需求结构化、风险规则匹配、五维风险评分、生成权限决策、伦理设计契约、受控生成和生成后审查构成闭环。大模型主要承担自然语言理解和方案生成任务，伦理边界则由外部规则引擎和审查流程控制。

关键词：大模型伦理；价值手册；风险控制；AI 辅助开发；负责任创新

目录

1	项目背景	3
2	项目需求分析	3
3	总体系统设计	3
4	详细设计	4
4.1	价值手册设计	4
4.2	风险控制引擎设计	4
4.3	伦理设计契约	4
4.4	受控生成与后置审查	5
5	系统实现	5
6	系统使用说明	5

7	伦理设计体现与局限	7
8	初步用户反馈	7
9	总结	8

1 项目背景

生成式人工智能显著降低了软件开发和项目构建门槛。用户输入“人脸识别考勤系统”“自动筛选简历工具”等自然语言需求后，大模型即可生成系统架构、功能模块乃至代码框架。然而，该能力也带来新的伦理挑战：模型可能协助构建侵犯隐私的系统，生成歧视性自动化决策逻辑，或被用于隐蔽监控、批量爬取、绕过安全限制等双重用途行为。

因此，本项目关注的并非一般性的 AI 项目伦理评估，而是更具体地讨论：当大模型参与项目构建时，如何在生成流程中嵌入可执行的伦理控制机制。EthicBuild 的目标是将抽象伦理原则转化为系统约束，使大模型辅助开发受到明确的价值边界、风险等级和审查流程限制。

2 项目需求分析

系统面向课程项目设计、原型开发和 AI 应用构思等场景，目标用户为希望使用大模型辅助构建项目的学生、开发者或研究者。系统功能需求如下：

1. **项目需求输入：**用户输入自然语言形式的项目设想，包括功能、场景、目标用户和涉及的数据。
2. **需求结构化：**系统将自然语言需求转化为应用领域、数据类型、目标用户、功能能力、自动化决策类型和潜在滥用表达等可审查字段。
3. **伦理风险识别：**系统依据价值手册识别隐私、偏见、安全、透明性和人类监督等风险。
4. **风险评分与决策：**系统从数据敏感性、影响严重性、自动化程度、脆弱群体和滥用可能性五个维度进行 0-15 分评分，并输出生成权限。
5. **伦理设计契约：**系统在生成项目方案前明确允许功能、禁止功能、必须控制措施、数据边界、人工复核要求和部署限制。
6. **受控项目生成：**系统生成符合伦理设计契约的项目方案，或对高风险需求提供低风险替代方案。
7. **生成后审查与审计：**系统检查输出是否遗漏控制措施或误生成禁止功能，并记录审计日志。

非功能需求包括低算力、可解释、可追溯、可离线运行和可扩展。系统不进行模型微调，而是通过规则引擎和 API 调用完成需求理解与方案生成。

3 总体系统设计

EthicBuild 的整体流程如下：

用户需求 → 需求结构化 → 价值手册匹配 → 风险评分与生成权限决策 → 伦理设计契约
→ 受控项目方案生成 → 生成后审查 → 审计记录

系统的关键设计是将“伦理引擎”从大模型中分离出来。大模型可以辅助语义理解并生成更完整的方案文本，但不能单独决定是否允许生成、必须加入哪些保护机制、哪些功能应被禁止。这些判断主要由 `data/ethics_manual.yaml` 和 `RiskEngine` 完成，从而避免系统退化为简单的提示词工程。

4 详细设计

4.1 价值手册设计

价值手册是系统核心，包含价值原则、风险模式、控制措施和决策规则四层。价值原则包括隐私保护、数据最小化、公平与反歧视、安全防滥用、透明性、人类监督、责任追溯和科技向善。风险模式包括敏感数据处理、生物识别、自动化高影响决策、歧视性筛选、未经授权数据抓取、监控追踪和提示注入等。控制措施包括知情同意、匿名化、敏感属性剔除、公平性测试、人工复核、申诉渠道、AI 使用披露和审计日志。

例如，当系统识别到“招聘场景 + 自动评分 + 年龄/性别/学校”等信息时，会触发 `FAIRNESS_HIGH_IMPACT_DECISION_001` 规则。该规则要求删除敏感属性，并加入可解释评分、人工复核、公平性测试和申诉渠道。

4.2 风险控制引擎设计

风险控制引擎不依赖大模型自由判断风险，而是依据结构化字段进行规则匹配。系统先抽取应用领域、数据类型、目标用户、功能能力和滥用表达，再从五个维度计算风险分数，并对应低、中、高、严重四类风险等级。

系统进一步输出四类生成权限：`allow`、`allow_with_controls`、`rewrite_required` 和 `block`。例如，学习计划生成器通常允许生成；学习行为课程推荐需要加入告知和退出机制；根据性别年龄筛选简历需要重写；批量爬取手机号且不告知应拒绝。

4.3 伦理设计契约

伦理设计契约是本项目的重要创新点。系统在调用大模型生成方案前先生成结构化契约，明确允许功能、禁止功能、必须控制措施、数据边界、透明性要求、人工复核要求和部署限制。后续生成结果必须遵守该契约。

这一机制将伦理原则转化为工程约束。例如，在简历筛选案例中，契约允许岗位技能匹配和面试问题建议，但禁止按性别、年龄、地域直接筛选，并强制加入人工复核、评分解释、申诉渠道和审计日志。

4.4 受控生成与后置审查

系统支持模板生成和大模型 API 生成。模板生成保证无 API 时仍可运行；大模型生成用于提高表达质量和方案完整度。无论采用何种方式，生成前均须经过风险决策和伦理设计契约约束。

生成后审查模块会检查输出是否遗漏控制措施、是否把禁止功能写成可执行方案、是否缺少数据边界或人工复核。审计模块记录原始需求、触发规则、风险等级、决策结果和人工确认状态，为责任追溯提供依据。

5 系统实现

系统使用 Python 实现，前端采用 Streamlit。核心文件包括：`app.py` 负责网页交互；`extractor.py` 负责需求结构化；`risk_engine.py` 负责规则匹配和评分；`contract.py` 负责伦理设计契约；`generator.py` 负责受控方案生成；`review.py` 负责后置审查；`audit.py` 负责审计记录。价值手册位于 `data/ethics_manual.yaml`，可继续扩展。

系统默认可离线运行；如果后台配置 API Key，则默认使用 `doubao-1.5-pro-32k-character-250715` 启用完整增强。该设计避免了大模型微调所需的高算力，同时保留了大模型在自然语言理解和方案生成方面的优势。

6 系统使用说明

安装依赖后运行：

```
pip install -r requirements.txt
streamlit run app.py
```

用户在网页中输入项目需求，点击“生成伦理可控项目方案”。系统会展示风险等级、风险评分、生成权限和后置审查结果。用户可在不同标签页查看结构化需求、触发规则、伦理设计契约、受控项目方案和审计记录，也可通过命令行运行示例：

```
python -m ethicbuild.cli --example high
python -m ethicbuild.cli --example block --json
```

若启用大模型增强，只需在后台提供 API Key。系统默认使用 `doubao-1-5-pro-32k-character-250715`，前端不展示 API Key、Base URL 或模型选择。完整增强模式中，LLM 参与需求识别和完整 Markdown 方案生成；本地价值手册负责风险决策、伦理契约、输出审查和必要结构校验，以避免内容失衡或遗漏代码架构。

系统界面如图 1 和图 2 所示。图 1 展示需求输入页和系统能力说明；图 2 展示生成后的风险与决策总览，以及完整项目方案、伦理风险分析、伦理设计契约和审计记录等结果标签页。

The screenshot displays the EthicBuild web interface. At the top, a navigation bar includes 'Value Manual', 'Risk Engine', and 'LLM Guardrails'. The main header reads 'EthicBuild · 伦理可控的 AI 辅助项目构建系统'. Below this, a descriptive paragraph explains the system's workflow: '面向“大模型辅助项目开发”的伦理风险控制原型：用户输入项目需求后，系统先进行需求识别、价值手册匹配和风险决策，再生成兼顾真实实现与伦理约束的项目方案。'

The interface is divided into two main sections:

- 需求输入 (Requirement Input):** This section contains a large text input area and a row of risk level buttons: '自定义' (Custom), '低风险·学习计划生成器' (Low Risk·Learning Plan Generator), '中风险·学习行为课程推荐' (Medium Risk·Learning Behavior Course Recommendation - highlighted in red), '高风险·简历自动筛选' (High Risk·Resume Auto-Selection), and '拒绝类·批量爬取手机号' (Refusal Type·Batch Scraping of Mobile Numbers). Below the input area is a text box with the prompt: '帮我做一个根据学生学习行为推荐课程的系统，需要分析学习时长、点击记录和作业完成情况。' At the bottom of this section is a red button labeled '生成伦理可控项目方案' (Generate Ethically Controllable Project Solution).
- 系统能力 (System Capabilities):** This section lists four core capabilities in a grid:
 - 需求识别 (Requirement Identification):** 抽取领域、数据、能力和影响权益 (Extract domain, data, capabilities, and impact rights).
 - 风险决策 (Risk Decision):** 根据价值手册输出允许、重写或拒绝 (Output allow, rewrite, or refuse based on the value manual).
 - 方案生成 (Solution Generation):** 生成真实功能、架构、代码模块和实现逻辑 (Generate real functions, architecture, code modules, and implementation logic).
 - 伦理审查 (Ethical Review):** 检查禁止功能、控制措施和审计记录 (Check prohibited functions, control measures, and audit records).

图 1: EthicBuild 需求输入与能力说明界面

3. 风险与决策总览



4. 结果详情

[完整项目方案](#) [伦理风险分析](#) [伦理设计契约](#) [审计记录](#)

项目名称：伦理可控的学生课程推荐系统构建方案

1. 项目定位

本项目旨在开发一个学生课程推荐系统，通过分析学生的学习时长、点击记录和作业完成情况等学习行为数据，为学生提供个性化的课程推荐，帮助学生更高效地选择适合自己的课程，提升学习效果。同时，项目将严格遵循伦理设计契约，确保系统在数据处理、决策过程等方面符合伦理要求，保护学生的权益和隐私。

2. 功能需求设计

- **学习行为数据收集**：系统能够收集学生在学习平台上的学习时长、点击记录和作业完成情况等数据。
- **数据分析与建模**：对收集到的学习行为数据进行分析，建立学生的学习画像，包括学习兴趣、学习进度、薄弱环节等。
- **课程推荐**：根据学生的学习画像，为学生推荐适合的课程，推荐结果应具有可解释性。

图 2: EthiBuild 风险总览与结果详情界面

7 伦理设计体现与局限

本项目体现的伦理设计主要包括：第一，价值设计，即把隐私、公平、安全、透明、人类监督等价值编码为规则；第二，安全设计，即对绕过限制、未经授权采集、隐蔽监控等需求进行拒绝或重写；第三，公平设计，即在高影响场景中限制敏感属性和歧视性自动决策；第四，透明设计，即说明风险等级、触发规则和需求修改原因；第五，人类监督设计，即要求高风险项目保留人工复核和申诉渠道；第六，责任追溯设计，即保存审计日志。

系统仍存在一定局限。规则库无法覆盖所有语境，关键词匹配可能出现误判或漏判；大模型增强虽然可以提高语义识别能力，但也可能产生幻觉或遗漏；伦理判断具有情境性，不能完全由自动化系统替代。因此，EthiBuild 更适合作为课程原型和伦理辅助工具，而不宜直接部署到真实高风险决策场景。

8 初步用户反馈

项目完成后收集了 3 位同学的试用反馈，结果如表 1 所示。

表 1: EthicBuild 用户试用反馈汇总

用户	界面 清晰度	风险 发现	决策 理解	方案 实用性	伦理 清晰度	技术/伦理 比例	认可重写 或拒绝	后续使用 意愿
用户 1	4	3	4	4	4	合适	4	愿意
用户 2	5	4	3	4	4	合适	5	愿意
用户 3	4	3	3	3	3	合适	4	不确定

量化结果显示，界面清晰度平均分为 4.33/5，伦理风险发现和生成权限理解平均分均为 3.33/5，方案实用性和伦理清晰度平均分均为 3.67/5。3 位用户均认为技术方案与伦理内容比例合适；对高风险需求重写或拒绝机制的认可度平均分为 4.33/5。后续使用意愿方面，2 位用户表示愿意，1 位用户表示不确定。用户建议系统未来可尝试将伦理审查能力融入其他 AI 平台或真实应用场景。总体来看，用户较认可系统界面和高风险控制机制，但风险解释的直观性仍有改进空间。

9 总结

本文围绕“大模型辅助项目构建中的伦理可控性”展开系统设计与实现，完成了 EthicBuild 原型系统。项目将抽象伦理原则转化为可执行的价值手册、风险规则、评分机制和伦理设计契约，并在生成流程中形成需求结构化、风险识别、权限决策、受控生成、后置审查和审计记录的闭环。与单纯依赖提示词约束的大模型应用不同，本系统将伦理判断从模型生成过程外置到可检查、可扩展的规则与审查机制中，使项目方案生成具有更明确的价值边界和责任追溯路径。

从实现效果看，EthiсBuild 能够在低算力条件下完成对典型项目需求的伦理风险识别和生成控制，并通过网页界面展示风险等级、触发规则、伦理设计契约和最终方案。初步用户反馈表明，系统界面、风险重写和拒绝机制具有较好的可接受性，同时也提示风险解释的直观性仍有进一步优化空间。后续工作可围绕风险规则库扩展、多轮交互式需求澄清、跨平台接入以及更细粒度的解释机制继续完善，使系统从课程原型进一步发展为更通用的负责任 AI 辅助开发工具。